

BAB 4

HASIL PENELITIAN DAN PEMBAHASAN

Percobaan diimplementasikan dengan menggunakan bahasa pemrograman Python 2.7 dan beberapa library eksternal. Adapun library eksternal yang digunakan adalah scipy, numpy, matplotlib dan scikit-learn (Pedregosa, et al., 2011).

Source code program dan hasil lengkap pengujian telah diletakkan di repository *github*. Repository tersebut berlisensi open-source dan bisa diakses secara publik di alamat <https://github.com/goFrendiAsgard/feature-extractor> dengan lisensi GNU, sehingga bebas dimodifikasi dan digunakan guna penelitian lebih lanjut.

4.1 Pengujian

Dalam percobaan yang dilakukan terdapat beberapa metode (GA Select, GE Global, GE Multi, GE Tatami dan GE Gavrilis) yang diujikan pada berbagai macam data. Selain itu, disertakan pula akurasi *classifier* tanpa ekstraksi fitur sebagai pembanding. Setiap data diuji dengan menggunakan *5 fold cross validation*.

4.1.1 Dataset Sintesis 01

Untuk kepentingan uji coba penelitian, maka dibuat beberapa buah dataset sintesis menggunakan aplikasi spreadsheet. Dalam penelitian ini digunakan libre-office.

Pada dataset sintesis 01, terdapat 3 buah kelas, yakni *defender*, *demon hunter* dan *wizard*. Ketiga kelas tersebut didapatkan dengan melakukan kalkulasi berdasarkan 4 fitur (*defense*, *attack*, *agility*, *stamina*). Keempat fitur yang ada bersifat random uniform dan memiliki range antara 0-10 dengan pembulatan satu angka di belakang koma. Dataset sintesis 01 terdiri dari 460 data yang terdiri dari 139 *defender*, 171 *demon hunter* dan 150 *wizard*. Data ini bisa diakses pada https://github.com/goFrendiAsgard/feature-extractor/blob/master/synthesis_01.csv.

Adapun Formula yang digunakan untuk menggolongkan kelas adalah sebagai berikut: $=IF(defense/attack \geq 1.4, "defender", IF(agility \geq stamina,$

"*demon hunter*", "*wizard*")). Pemilihan angka-angka pada formula semata-mata untuk membuat dataset *balanced* (memiliki jumlah data yang hampir sama untuk semua kelas). Formula tersebut dimaksudkan untuk membuat data yang hirarkikal. Melalui perbandingan fitur *defense* dan *attack*, kelas *defender* terpisah dari kedua kelas lainnya (*demon hunter* dan *wizard*). Melalui perbandingan fitur *agility* dan *stamina*, kelas *demon hunter* terpisah dari kelas *wizard*.

Hasil pengujian menunjukkan bahwa GE Multi dan GE Tatami memeberikan hasil yang cukup baik dengan jumlah fitur yang relatif sedikit. Pada fold 2, GE Gavrilis memperoleh akurasi tertinggi, namun memiliki jumlah fitur yang sangat banyak (48 fitur).

Hasil pengujian terhadap dataset sintesis 01 ditunjukkan dalam tabel 4.1

Tabel 4.1 Hasil Pengujian pada Dataset Sintesis 01

Percobaan		Tanpa Ekstraksi Fitur		Ekstraksi Fitur: GA Select		Ekstraksi Fitur: GE Global		Ekstraksi Fitur: GE Multi		Ekstraksi Fitur: GE Tatami		Ekstraksi Fitur: GE Gavrilis	
		Akurasi (%)	Jml. Fitur	Akurasi (%)	Jml. Fitur	Akurasi (%)	Jml. Fitur	Akurasi (%)	Jml. Fitur	Akurasi (%)	Jml. Fitur	Akurasi (%)	Jml. Fitur
Un-fold	Train	73.0	4	73.0	3	77.8	1	99.3	3	100	2	85.6	3
	Test	73.0		73.0		77.8		99.3		100		85.6	
	Total	73.0		73.0		77.8		99.3		100		85.6	
Fold 1	Train	75.9	4	75.9	3	78.9	1	100	3	100	2	84.5	61
	Test	67.7		67.7		35.5		76.6		81.1		83.3	
	Total	74.3		74.3		70.4		95.4		96.3		84.3	
Fold 2	Train	73.7	4	73.7	3	78.9	1	100	3	100	2	100	48
	Test	70.0		70.0		36.7		74.4		65.6		80.0	
	Total	73.0		73.0		70.6		95.0		93.2		96.0	
Fold 3	Train	71.6	4	71.6	3	77.5	1	100	3	100	2	85.1	3
	Test	75.5		75.5		25.5		86.6		86.7		86.7	
	Total	72.3		72.3		67.3		97.3		97.4		85.4	
Fold 4	Train	73.5	4	73.5	3	78.6	1	100	3	100	2	85.4	3
	Test	74.4		74.4		36.6		77.7		77.7		76.6	
	Total	73.7		73.7		70.4		95.6		95.6		83.7	
Fold 5	Train	75.6	4	75.6	3	81.0	1	100	3	100	2	87.0	2
	Test	70.0		42.2		42.2		94.4		82.2		72.2	
	Total	74.5		73.4		73.5		98.9		96.5		84.1	

4.1.2 Dataset Sintesis 02

Data sintesis 02 memiliki struktur yang hampir sama dengan data sintesis 01. Pada dataset ini terdapat 4 fitur dan 4 kelas.

Pada dataset sintesis 02, terdapat 3 buah kelas, yakni defender, demon hunter, monk dan wizard. Ketiga kelas tersebut didapatkan dengan melakukan kalkulasi berdasarkan 4 fitur (defense, attack, agility, stamina). Keempat fitur yang ada bersifat random uniform dan memiliki range antara 0-10 dengan pembulatan satu angka di belakang koma. Dataset sintesis 02 terdiri dari 613 data yang terdiri dari 184 defender, 148 demon hunter, 135 monk dan 146 wizard. Data ini bisa diakses pada alamat https://github.com/goFrendiAsgard/feature-extractor/blob/master/synthesis_02.csv.

Formula yang digunakan pada dataset sintesis 02 adalah sebagai berikut: $\text{=IF}(\text{defense}/\text{attack} \geq 1.6, \text{"defender"}, \text{IF}(\text{agility}/\text{stamina} \geq 1.3, \text{"demon hunter"}, \text{IF}(\text{stamina} > \text{defense}, \text{"monk"}, \text{"wizard"})))$. Sama seperti pada dataset sintesis 01, formula untuk membuat kelas pada data sintesis 02 juga dimaksudkan untuk membuat data yang hirarkikal. Melalui perbandingan fitur defense dan attack, kelas defender terpisah dari ketiga kelas lainnya (demon hunter, monk dan wizard). Melalui perbandingan fitur agility dan stamina, kelas demon hunter terpisah dari kelas monk dan wizard. Terakhir, melalui perbandingan fitur stamina dan defense, kelas monk dan wizard terpisah satu sama lain. Dibandingkan dengan data sintesis 01, data sintesis 02 ini memiliki struktur hirarkikal yang lebih dalam, dikarenakan jumlah kelasnya lebih banyak.

Pada Data sintesis 02, GE Multi tidak lagi memberikan performa sebaik pada dataset sintesis 01. Hal tersebut disebabkan karena dengan semakin banyaknya kelas, pemisahan satu kelas terhadap semua kelas lain akan menjadi semakin sulit. Sebaliknya GE Tatami justru menunjukkan hasil yang lebih baik, dikarenakan struktur hirarkikal yang lebih tampak.

Hasil pengujian terhadap dataset sintesis 02 ditunjukkan dalam tabel 4.2

Tabel 4.2 Hasil Pengujian pada Dataset Sintesis 02

Percobaan	n	Tanpa Ekstraksi Fitur		Ekstraksi Fitur: GA Select		Ekstraksi Fitur: GE Global		Ekstraksi Fitur: GE Multi		Ekstraksi Fitur: GE Tatami		Ekstraksi Fitur: GE Gavrilis	
		Akurasi (%)	Jml. Fitur	Akurasi (%)	Jml. Fitur	Akurasi (%)	Jml. Fitur	Akurasi (%)	Jml. Fitur	Akurasi (%)	Jml. Fitur	Akurasi (%)	Jml. Fitur
Un-fold	Train	77.9	4	77.9	4	70.8	1	100	4	100	3	90.3	12
	Test	77.9		77.9		70.8		100		100		90.3	
	Total	77.9		77.9		70.8		100		100		90.3	
Fold 1	Train	78.7	4	78.7	4	73.2	1	99.4	4	100	3	89.8	12
	Test	76.0		76.0		33.1		46.3		62.8		72.7	
	Total	78.1		78.1		65.2		88.9		92.6		86.4	
Fold 2	Train	76.4	4	76.4	4	70.5	1	100	4	100	3	89.4	12
	Test	77.6		77.6		27.2		72.7		74.3		85.9	
	Total	76.6		76.6		61.9		94.6		94.9		88.7	
Fold 3	Train	79.6	4	79.6	4	71.7	1	99.3	3	100	3	90.0	12
	Test	68.6		68.6		34.7		64.4		83.4		68.6	
	Total	77.4		77.4		64.4		92.5		96.7		85.8	
Fold 4	Train	79.0	4	79.0	4	70.7	1	100	4	100	3	90.2	12
	Test	72.7		72.7		40.5		71.0		61.1		80.1	
	Total	77.8		77.8		64.7		94.2		92.3		88.2	
Fold 5	Train	78.0	4	78.0	4	71.7	1	100	4	100	3	86.9	12
	Test	73.5		73.5		32.2		83.4		94.2		70.2	
	Total	77.1		77.1		63.9		96.7		98.8		83.6	

4.1.3 Dataset Sintesis 03

Dataset sintesis 03 merupakan dataset ideal untuk GE Tatami. Dataset ini terdiri dari 400 data yang terdiri dari 91 kelas A, 81 kelas B, 81 kelas C, 59 kelas D, dan 88 kelas E. Dalam dataset ini terdapat 5 kelas, A, B, C, D dan E dan 7 fitur (f1, f2, f3, f4, f5, n1, dan n2). Fitur n1 dan fitur n2 adalah fitur noise yang bersifat random uniform dengan ketelitian 1 angka di belakang koma. Keberadaan kedua fitur noise tersebut dimaksudkan untuk menguji apakah metode-metode yang ada dapat memfilter dan menghilangkan noise. Fitur f1 sampai f5 merupakan fitur utama yang diperoleh melalui serangkaian perhitungan.

Pembagian data ke dalam 5 kelas ditentukan berdasarkan 4 fitur tersembunyi m1, m2, m3, dan m4. Fitur m1, m2, m3 dan m4 bersifat random uniform dan memiliki range antara 0-10 dengan ketelitian 1 angka di belakang koma. Penentuan kelas menggunakan formula sebagai berikut: $=IF(m1 < 0.5, "A",$

$IF(m2 < 0.5, "B", IF(m3 < 0.5, "C", IF(m4 < 0.5, "D", "E"))))$). Fitur m1 memisahkan kelas A dengan keempat kelas lainnya (B, C, D, dan E). Fitur m2 memisahkan kelas B dengan ketiga kelas lain (C, D, dan E). Fitur m3 memisahkan kelas C dari kelas D dan E. Terakhir, fitur m4 berfungsi untuk memisahkan kelas D dan E.

Seperti yang telah diungkapkan, fitur m1 sampai m4 tidak ditunjukkan secara eksplisit kepada sistem, melainkan disembunyikan secara implisit melalui formula-formula matematis sederhana ke dalam lima fitur tampak f1 sampai f5. Hal ini dimaksudkan untuk menguji kemampuan GE Tatami dalam memperoleh kembali fitur-fitur utama tersembunyi (m1-m4) berdasarkan fitur-fitur tampak. Proses penyembunyian m1-m4 ke dalam f1-f5 dilakukan sebagai berikut:

- f1 diperoleh secara acak dengan formula $=ROUND(RAND() * 9.9 + 0.1, 3)$
- f2 diperoleh dengan menggunakan rumus $f2 = f1/m1$
- f3 diperoleh dengan menggunakan rumus $f3 = f2/m2$
- f4 diperoleh dengan menggunakan rumus $f4 = m3/f1$
- f5 diperoleh dengan menggunakan rumus $f5 = f4/m4$

Diharapkan GE Tatami akan berhasil menemukan m1-m4 dengan menggunakan konstruksi matematis dari f1-f5. Iterasi pertama dalam GE Tatami diharapkan mampu menemukan f1/f2 atau bentuk lain yang sebanding dengan m1 ($f2 = f1/m1$ sehingga $m1 = f1/f2$). Fitur ini seharusnya mampu memisahkan kelas A dengan keempat kelas lainnya (B, C, D dan E). Pada iterasi kedua, GE Tatami diharapkan mampu menemukan f2/f3 atau bentuk lain yang sebanding dengan m2 ($f3 = f2/m2$ sehingga $m2 = f2/f3$). Demikian seterusnya hingga m4-m5 atau fitur-fitur yang sebanding dengan itu ditemukan.

Data sintesis 03 dapat diakses melalui alamat https://github.com/goFrendiAsgard/feature-extractor/blob/master/synthesis_03.csv

Hasil pengujian menunjukkan bahwa untuk dataset sintesis 03, GE Tatami menunjukkan hasil yang sangat baik.

Berikut adalah keempat fitur yang berhasil di-generate oleh GE Tatami pada skenario unfold guna memisahkan kelima kelas yang ada:

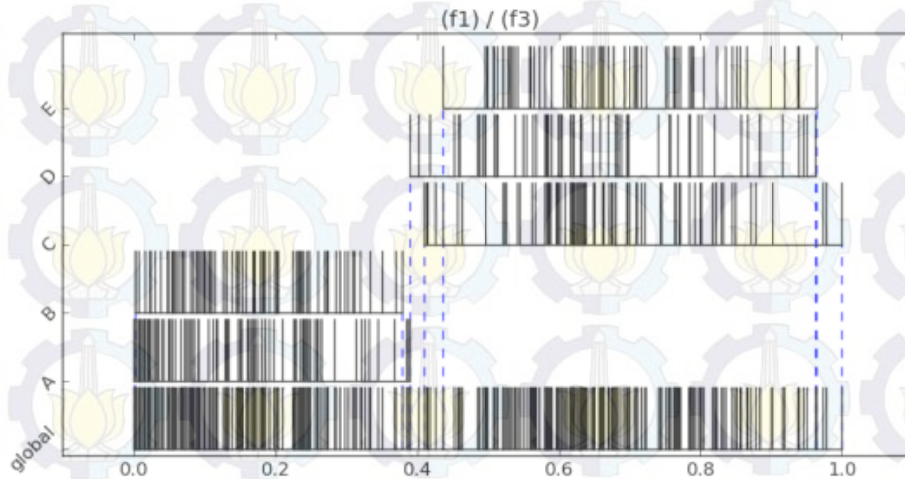
- $(f2) / (f1)$

- $(f1) / (f3)$
- $\text{sqrt}(\text{sqrt}(((f4) * (\text{sqrt}(\text{sqrt}(f1+f1)/2)))) - (n1)+n1)/2)$
- $(f5) / (f4)$


Dari keempat fitur tersebut, tampak bahwa fitur pertama $(f2) / (f1)$ sebanding dengan $m1$, sebab $m1 = f2/f1$. Fitur ke empat $(f5) / (f4)$ juga sebanding dengan $m4$, sebab $m4 = f5/f4$. Sementara itu, fitur kedua $(f1) / (f3)$ dan fitur ketiga $\text{sqrt}(\text{sqrt}(((f4) * (\text{sqrt}(\text{sqrt}(f1+f1)/2)))) - (n1)+n1)/2)$ walaupun masing-masing tidak sama dengan $m2$ dan $m3$, namun mampu memisahkan kelas-kelas yang sesuai dengan baik.

Fitur kedua sanggup memisahkan kelas B dengan kelas C, D dan E, seperti yang ditunjukkan dalam gambar 4.1. Fitur ketiga sanggup memisahkan kelas C dengan kelas D dan E, seperti yang ditunjukkan dalam gambar 4.2.

Hasil pengujian terhadap dataset sintesis 03 ditunjukkan dalam tabel 4.3



Gambar 4.1 Proyeksi data terhadap fitur $(f1)/(f3)$.



Gambar 4.2 Proyeksi data terhadap fitur $\sqrt{\sqrt{((f_4) * (\sqrt{\sqrt{f_1 + f_1} / 2))}} - ((n_1) + n_1) / 2}$.

Tabel 4.3 Hasil Pengujian pada Dataset Sintesis 03

Percobaan	Tanpa Ekstraksi	Ekstraksi Fitur: GA		Ekstraksi Fitur: GE		Ekstraksi Fitur: GE		Ekstraksi Fitur: GE		Ekstraksi Fitur: GE	
		Akurasi (%)	Jml. Fitur	Akurasi (%)	Jml. Fitur	Akurasi (%)	Jml. Fitur	Akurasi (%)	Jml. Fitur	Akurasi (%)	Jml. Fitur
Un-fold	Train	72.5	7	72.5	6	67.0	1	98.2	5	100	4
	Test	72.5		72.5		67.0		98.2		100	
	Total	72.5		72.5		67.0		98.2		100	
Fold 1	Train	74.4	7	74.4	6	67.9	1	99.0	5	100	4
	Test	26.5		26.5		27.8		45.5		63.2	
	Total	65.0		65.0		60.0		88.5		92.7	
Fold 2	Train	72.9	7	72.9	6	66.9	1	100.	5	100.	4
	Test	62.0		62.0		27.8		68.3		94.9	
	Total	70.7		70.7		59.2		93.7		99.0	
Fold 3	Train	71.3	7	71.3	6	69.4	1	99.6	5	100	4
	Test	29.1		29.1		24.0		55.7		65.8	
	Total	63.0		63.0		60.5		91.0		93.2	
Fold 4	Train	72.9	7	72.9	4	66.9	1	98.4	5	100	4
	Test	26.5		27.8		26.5		50.6		78.4	
	Total	63.7		64.0		59.0		89.0		95.7	
Fold 5	Train	72.2	7	72.2	6	68.8	1	99.3	5	100	4
	Test	24.0		25.3		48.1		59.4		63.2	
	Total	62.7		63.0		64.7		91.5		92.7	

4.1.4 Dataset Iris

Dataset iris merupakan dataset yang cukup banyak dipakai dalam penelitian. Data ini terdiri dari 3 kelas (Iris-Setosa, Iris-Versicolor, dan Iris-Virginica) serta 4 atribut fitur original (Sepal Length, Sepal Width, Petal Length, dan Petal Width) yang memiliki ketelitian 1 angka di belakang koma. Dataset iris bersifat multi-variate, terdiri dari 150 data (50 iris-setosa, 50 iris-versicolor, dan 50 iris-virginica). Dataset iris dapat didownload dari website UCI Machine Learning dengan alamat (<http://archive.ics.uci.edu/ml/datasets/Iris>)

Hasil pengujian terhadap data iris menunjukkan hasil yang hampir seimbang untuk GE Global, GE Multi, GE Tatami dan GE Gavrilis. Namun tampak bahwa GE Gavrilis memberikan hasil yang sedikit lebih unggul dibandingkan metode-metode lain.

Hasil pengujian terhadap dataset iris ditunjukkan dalam tabel 4.4

Tabel 4.4 Hasil Pengujian pada Dataset Iris.

Percobaan		Tanpa Ekstraksi Fitur	Ekstraksi Fitur: GA Select		Ekstraksi Fitur: GE Global		Ekstraksi Fitur: GE Multi		Ekstraksi Fitur: GE Tatami		Ekstraksi Fitur: GE Gavrilis	
		Akurasi (%)	Jumlah Fitur	Akurasi (%)	Jumlah Fitur	Akurasi (%)	Jumlah Fitur	Akurasi (%)	Jumlah Fitur	Akurasi (%)	Jumlah Fitur	
Un-fold	Train	96.04	2	98.6	1	98.6	3	98.6	2	98.6	1	
	Test	96.0		98.6		98.6		98.6		98.6		
	Total	96.0		98.6		98.6		98.6		98.6		
Fold 1	Train	96.64	2	99.1	1	99.1	3	98.3	2	99.1	1	
	Test	86.6		96.6		96.6		96.6		96.6		
	Total	94.6		98.6		98.6		98.0		98.6		
Fold 2	Train	95.84	2	100	1	99.1	3	99.1	2	100	3	
	Test	96.6		96.6		83.3		66.6		96.6		
	Total	96.0		99.3		96.0		92.6		99.3		
Fold 3	Train	96.64	2	98.3	1	98.3	3	99.1	2	98.3	1	
	Test	93.3		76.6		100		100		100		
	Total	96.0		94.0		98.6		99.3		98.6		
Fold 4	Train	95.84	2	99.1	1	99.1	3	99.1	2	99.1	1	
	Test	96.6		93.3		96.6		96.6		96.6		
	Total	96.0		98.0		98.6		98.6		98.6		
Fold 5	Train	96.64	2	98.3	1	98.3	3	99.1	2	99.1	3	
	Test	93.3		93.3		93.3		96.6		96.6		
	Total	96.0		97.3		97.3		98.6		98.6		

4.1.5 Dataset E-Coli

Data E-Coli merupakan dataset yang cukup banyak dipakai dalam penelitian. Data ini terdiri dari 7 atribut (mcg, gvh, lip, chg, aac, alm1, alm2) dan 6 kelas (cp, im, imU, om, omL, pp), yang terdiri dari 335 record (143 cp, 77 im , 52 pp, 35 imU, 20 om, 5 omL, 2 imL, 2 imS). Masing-masing atribut memiliki ketelitian satu angka di belakang koma. Dataset ini merupakan klasifikasi terhadap berbagai varian dari bakteri E-Coli. Dataset E-Coli dapat didownload pada alamat (<http://archive.ics.uci.edu/ml/datasets/Ecoli>).

Berbeda dengan pengujian-pengujian sebelumnya, di sini justru GA Select menghasilkan akurasi yang paling tinggi dibandingkan keempat skenario lain. Adapun demikian, saat semua data digunakan untuk training sekaligus testing, GE Tatami tampak berhasil memberikan akurasi yang paling tinggi. Dalam beberapa kasus, terlihat bahwa penggunaan fitur original justru memberikan hasil yang lebih baik (semisal pada fold 1, 2 dan 4). Hal ini dikarenakan bahwa pengekstraksian fitur menjadi jumlah yang lebih sedikit dari fitur original juga menyebabkan hilangnya sebagian informasi yang berguna dalam proses klasifikasi.

Hasil pengujian terhadap dataset e-coli ditunjukkan dalam tabel 4.5

Tabel 4.5 Hasil Pengujian pada Dataset E-Coli

Percobaan	Tanpa Ekstraksi Fitur	Ekstraksi Fitur: GA Select		Ekstraksi Fitur: GE Global		Ekstraksi Fitur: GE Multi		Ekstraksi Fitur: GE Tatami		Ekstraksi Fitur: GE Gavrilis	
		Akurasi (%)	Jml. Fitur	Akurasi (%)	Jml. Fitur	Akurasi (%)	Jml. Fitur	Akurasi (%)	Jml. Fitur	Akurasi (%)	Jml. Fitur
Un-fold	Train	97.0	7	84.5	1	96.7	8	97.6	7	97.0	12
	Test	97.0		84.5		96.7		97.6		97.0	
	Total	97.0		84.5		96.7		97.6		97.0	
Fold 1	Train	97.4	7	87.4	1	98.8	8	96.3	7	97.7	12
	Test	73.8		58.4		53.8		53.8		69.2	
	Total	92.8		81.8		90.1		88.1		92.2	
Fold 2	Train	96.6	7	86.7	1	97.7	8	98.5	7	97.7	12
	Test	81.5		63.0		49.2		1.54		58.4	
	Total	93.7		82.1		88.3		79.7		90.1	
Fold 3	Train	97.7	7	89.3	1	99.2	8	97.0	7	98.5	26
	Test	70.7		53.8		80.0		69.2		53.8	
	Total	92.5		82.4		95.5		91.6		89.8	

Fold 4	Train	95.97	96.3	5	87.0	1	98.5	8	97.4	7	98.1	12
	Test	73.8	73.8		69.2		63.0		43.0		56.9	
	Total	91.6	91.9		83.6		91.6		86.9		90.1	
Fold 5	Train	97.07	97.0	4	86.7	1	98.1	8	96.3	7	98.8	18
	Test	73.8	75.3		61.5		38.4		38.4		67.6	
	Total	97.4	97.4		87.4		98.8		96.3		97.7	

4.1.6 Dataset Balanced-Scale

Dataset balanced-scale terdiri dari 625 data yang masing-masing terdiri dari 4 fitur(left_weight, left_distance, right_weight, right_distance) dan 3 kelas(B, R, L). Masing-masing atribut bertipe bilangan bulat positif dengan range antara 1-5. Dataset ini terdiri dari 625 record yang terdiri dari 49 B, 288 L, dan 288 R. Dataset ini dibuat untuk tujuan pengujian psikologi dan dapat didownload pada alamat (<http://archive.ics.uci.edu/ml/datasets/Balance+Scale>).

Hasil pengujian menunjukkan bahwa secara umum GE Multi lebih unggul dibandingkan semua metode lain.

Tabel 4.6 Hasil Pengujian pada Dataset Balanced-Scale

Percobaan	Tanpa Ekstraksi Fitur	Akurasi (%)	Jml. Fitur	Ekstraksi Fitur: GA Select	Akurasi (%)	Jml. Fitur	Ekstraksi Fitur: GE Global	Akurasi (%)	Jml. Fitur	Ekstraksi Fitur: GE Multi	Akurasi (%)	Jml. Fitur	Ekstraksi Fitur: GE Tatami	Akurasi (%)	Jml. Fitur	Ekstraksi Fitur: GE Gavrilis	Akurasi (%)	Jml. Fitur
Un-fold	Train	70.8	4	70.8	3	84.8	1	91.6	1	91.6	2	82.5	9					
	Test	70.8		70.8		84.8		91.6		91.6		82.5						
	Total	70.8		70.8		84.8		91.6		91.6		82.5						
Fold 1	Train	68.7	4	70.9	3	100	1	100	1	92.0	2	81.0	4					
	Test	67.4		70.7		91.8		91.8		85.3		81.3						
	Total	68.4		70.8		98.4		98.4		90.7		81.1						
Fold 2	Train	70.1	4	71.9	3	85.4	1	92.2	1	92.6	2	83.8	9					
	Test	61.7		66.6		69.9		89.4		82.9		78.8						
	Total	68.4		70.8		82.4		91.6		90.7		82.8						
Fold 3	Train	69.3	4	70.5	3	90.0	1	99.0	2	92.0	2	83.6	126					
	Test	65.0		72.3		66.6		85.3		71.5		81.3						
	Total	68.4		70.8		85.4		96.3		88.0		83.2						
Fold 4	Train	72.5	4	72.5	3	86.6	1	100	1	91.8	2	82.2	2					
	Test	68.2		68.2		78.0		73.9		91.0		77.2						
	Total	71.6		71.6		84.9		94.8		91.6		81.2						
Fold 5	Train	71.1	4	71.1	3	84.6	1	94.6	3	100	2	82.8	1					
	Test	69.9		69.9		82.9		57.7		66.6		51.2						
	Total	70.8		70.8		84.3		87.3		93.4		76.6						

4.1.7 Rata-Rata Hasil Pengujian

Guna mendapatkan gambaran performa secara umum, maka dilakukan perhitungan terhadap rata-rata hasil pengujian terhadap keenam dataset yang digunakan.

Rata-rata akurasi yang diperoleh dari pengujian terhadap keenam dataset menunjukkan bahwa GE Multi memberikan hasil terbaik, sementara GE Tatami menempati peringkat kedua.

Adapun GE Tatami menunjukkan keunggulan mutlak pada data data sintesis 02 dan data sintesis 03. Kedua dataset tersebut dapat terpisah secara hirarkikal berdasarkan fitur-fitur yang di-generate. Keduanya juga memiliki jumlah kelas yang relatif cukup banyak (lebih dari tiga). Ini menunjukkan bahwa GE Tatami unggul dalam meningkatkan akurasi decision tree pada data-data yang dapat terpisah secara hirarkikal.

Pada data E-Coli, secara umum tampak bahwa penggunaan ekstraksi fitur seperti GE Global, GE Multi, GE Tatami, dan GE Gavrilis tidak meningkatkan akurasi decision tree, bahkan cenderung memperburuk akurasi (kecuali pada sesi training di mana rata-rata akurasi yang diberikan GE Tatami adalah sebesar 98,2%). Ini menunjukkan dua hal. Yang pertama adalah bahwa pada data-data dengan jumlah fitur yang relatif banyak (lebih banyak dari jumlah kelas), maka penggunaan ekstraksi fitur seperti GE Global, GE Multi, GE Tatami, dan GE Gavrilis, mungkin tidak akan banyak membantu. Yang kedua, adalah bahwa GE Tatami memiliki kecenderungan untuk menciptakan fitur-space yang overfit. Hal ini tampak dari perbedaan akurasi antara sesi training dan testing yang cenderung cukup besar.

Rata-rata hasil pengujian ditunjukkan pada tabel 4.7

Tabel 4.7 Rata-Rata Hasil Pengujian pada Keenam Dataset

Percobaan		Tanpa Ekstraksi Fitur		Ekstraksi Fitur: GA Select		Ekstraksi Fitur: GE Global		Ekstraksi Fitur: GE Multi		Ekstraksi Fitur: GE Tatami		Ekstraksi Fitur: GE Gavrilis	
		Akurasi (%)	Jml Fitur	Akurasi (%)	Jml Fitur	Akurasi (%)	Jml Fitur	Akurasi (%)	Jml Fitur	Akurasi (%)	Jml Fitur	Akurasi (%)	Jml Fitur
iris	Train	96.2	4	96.2	2	98.9	1	98.8	3	98.9	2	99.0	2
	Test	93.7		93.7		92.5		94.7		92.5		97.5	
	Total	95.7		95.7		97.6		98.0		97.6		98.7	
balance-scale	Train	70.4	4	71.3	3	88.6	1	96.2	2	93.3	2	82.7	25
	Test	67.2		69.8		79.0		81.6		81.5		75.4	
	Total	69.8		71.0		86.7		93.3		91.0		81.2	
ecoli	Train	96.9	7	97.0	6	86.9	1	98.2	8	97.2	7	98.0	15
	Test	78.4		78.2		65.1		63.5		50.6		67.2	
	Total	93.4		93.4		82.7		91.5		88.2		92.0	
synthesis_01	Train	73.9	4	73.9	3	78.8	1	99.8	3	100	2	87.9	20
	Test	71.8		71.8		42.42		84.8		82.2		80.7	
	Total	73.5		73.5		71.7		96.9		96.5		86.5	
synthesis_02	Train	78.3	4	78.3	4	71.4	1	99.8	4	100	3	89.4	12
	Test	74.4		74.4		39.7		73.0		79.3		78.0	
	Total	77.5		77.5		65.2		94.5		95.9		87.2	
synthesis_03	Train	72.7	7	72.7	6	67.8	1	99.1	5	100	4	81.9	19
	Test	40.1		40.5		36.9		63.0		77.6		50.8	
	Total	66.2		66.3		61.7		92.0		95.5		75.8	
All Average	Train	81.4	5	81.6	4	82.1	1	98.6	4	98.2	3	89.8	16
	Test	70.9		71.4		59.3		76.8		77.3		74.9	
	Total	79.3		79.6		77.6		94.4		94.1		86.9	

4.2 Analisis

Berdasarkan data-data pengujian yang didapat dalam subbab 4.1, dilakukan analisis untuk menjelaskan karakteristik dan kelemahan dari GE Tatami.

4.2.1 Karakteristik GE Tatami

Dari hasil percobaan, tampak bahwa GE Tatami menunjukkan hasil yang cukup baik pada data-data sintesis dan data iris. Dalam hal ini proses *grammatical evolution* berhasil menemukan fitur-fitur yang sanggup memisahkan data sesuai dengan hipotesis.

Pada dataset sintesis 03, tampak bahwa GE Tatami berhasil menemukan fitur-fitur yang sebanding (dalam hal pemisahan kelas) dengan fitur asli (m_1 , m_2 , m_3 dan m_4) berdasarkan fitur-fitur tampak (f_1 , f_2 , f_3 , f_4 dan f_5). Hubungan antara fitur asli dan fitur tampak telah dijelaskan pada subbab 4.3. Adapun fitur-fitur yang berhasil di-*generate* oleh GE Tatami adalah sebagai berikut:


- $(f_2) / (f_1)$
- $(f_1) / (f_3)$
- $\text{sqrt}(\text{sqrt}(((f_4) * (\text{sqrt}(\text{sqrt}(f_1+f_1)/2)))) - (n_1)+n_1)/2)$
- $(f_5) / (f_4)$

Fitur $(f_2) / (f_1)$ sanggup memisahkan kelas A dan keempat kelas lainnya. Hal ini tampak seperti pada gambar 4.3. Pada gambar 4.3, tampak bahwa kelas B, C, D dan E berimpit di sebelah kiri, terpisah secara linear dari kelas A. Panjang garis vertikal menunjukkan banyaknya data yang menempati nilai yang sama.


Setelah berhasil menemukan fitur $(f_2) / (f_1)$ yang memisahkan kelas A dan keempat kelas lain (B, C, D, dan E), GE Tatami mencari fitur yang paling baik memisahkan satu dari keempat kelas tersebut terhadap tiga kelas lainnya. Dalam proses ini ditemukan fitur $(f_1) / (f_3)$. Proyeksi data ke dalam fitur $(f_1) / (f_3)$ mengakibatkan kelas A tidak terpisah dengan kelas B. Namun hal ini tidak dipermasalahkan karena fitur sebelumnya, yakni $(f_2) / (f_1)$ telah memisahkan kelas A dengan semua kelas lain. Proyeksi data terhadap fitur $(f_1) / (f_3)$ telah digambarkan pada gambar 4.1.

Setelah kelas kedua fitur sebelumnya berhasil memisahkan kelas A dan B dari ketiga kelas lain (C, D, dan E), GE Tatami mencari fitur yang paling baik memisahkan satu dari ketiga kelas itu dari kedua kelas lainnya. Dalam proses ini ditemukan $\text{sqrt}(\text{sqrt}(((f_4) * (\text{sqrt}(\text{sqrt}(f_1 + f_1) / 2)))) - (n_1) + n_1) / 2)$ yang sanggup memisahkan C dari D dan E. Proyeksi data terhadap fitur ketiga ini telah digambarkan pada gambar 4.2.

Setelah hanya tersisa kelas D dan E, GE Tatami mencari fitur terakhir untuk memisahkan kedua kelas tersebut. Di sini ditemukan $(f_5) / (f_4)$. Fitur ini tampak berhasil memisahkan kelas D dan E dengan sangat baik, seperti yang ditunjukkan dalam gambar 4.4.



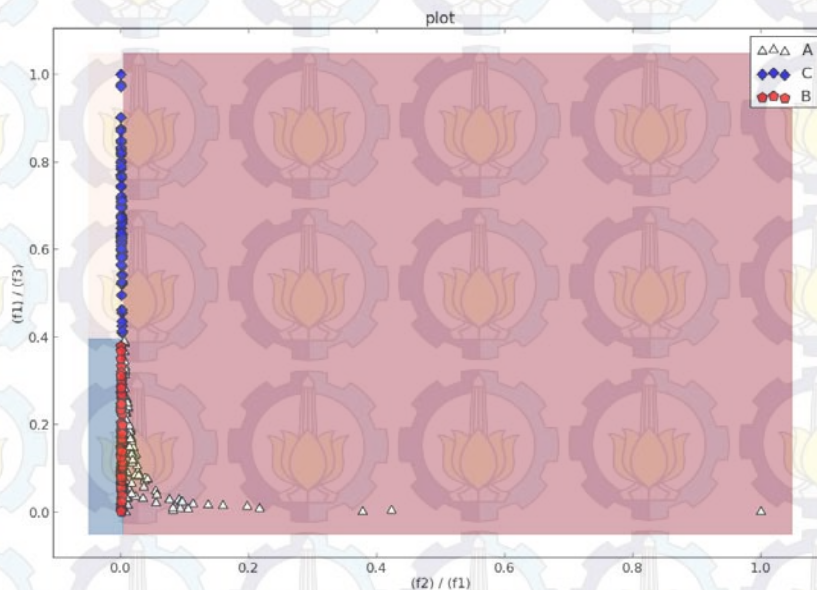
Gambar 4.3 Proyeksi Data terhadap Fitur $(f2) / (f1)$.



Gambar 4.4 Proyeksi Data terhadap Fitur $(f5) / (f4)$

Skenario GE Tatami tampak berhasil menciptakan feature space yang ideal bagi *classifierDecision Tree*, seperti ditunjukkan pada gambar 4.5. Fitur $(f2) / (f1)$ dan $(f3) / (f1)$, memberikan kemudahan bagi *decision tree* untuk membagi data sesuai dengan kelas yang ada.

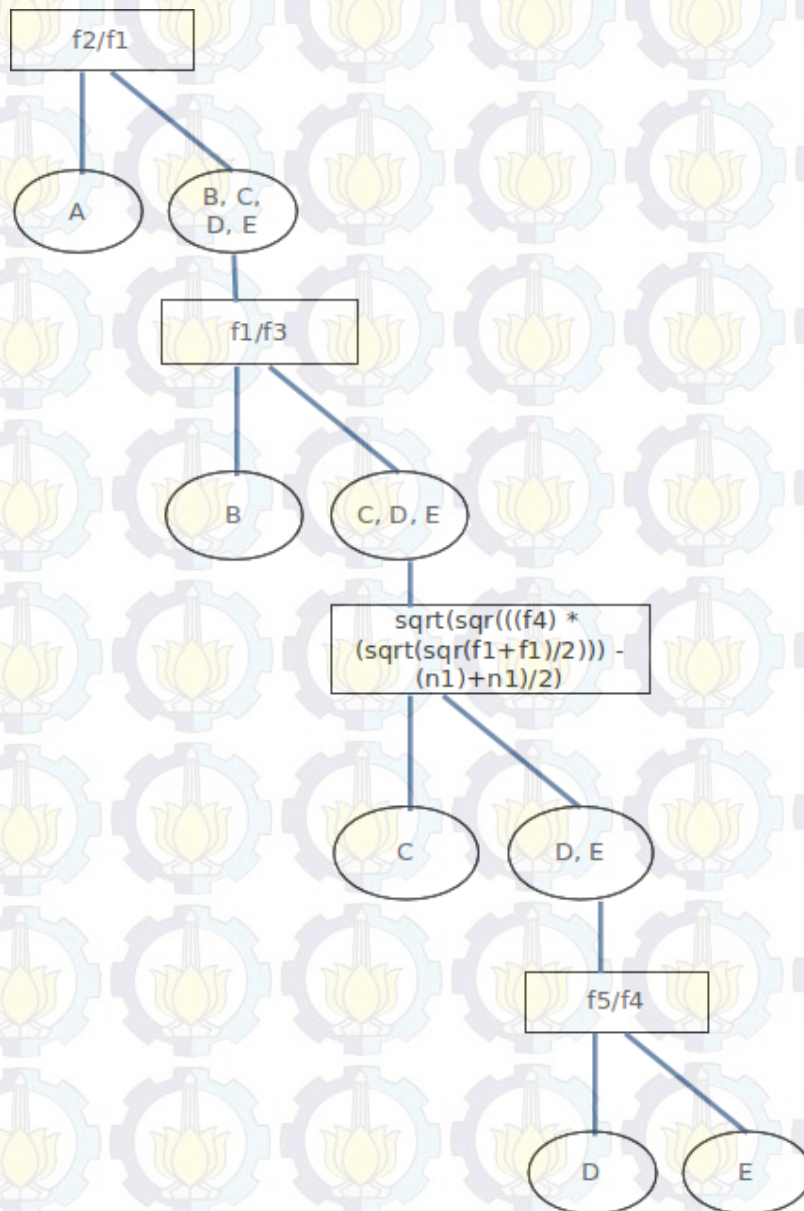
Cara kerja GE Tatami ini sangat sesuai dengan karakteristik *Decision Tree* yang memisahkan data secara hirarkikal seperti digambarkan dalam gambar 4.6.




Gambar 4.5 Proyeksi Data terhadap Fitur $(f2) / (f1)$ dan Fitur $(f1) / (f3)$ dengan *Decision Tree Classifier*

Sekalipun GE Tatami menunjukkan hasil yang baik jika dikombinasikan dengan *Decision Tree*, namun tampaknya penggunaan *classifier* lain semisal SVM. Proyeksi data yang sama jika menggunakan *classifier* SVM ditunjukkan pada gambar 4.7. Fenomena ini menunjukkan bahwa Feature Space yang di-*generate* oleh GE Tatami hanya akan membantu untuk *classifier* yang memanfaatkan keterpisahan data per fitur tanpa mempedulikan pola dan bentuk sebaran data.

Dari cara kerja yang telah dipaparkan, tampak bahwa GE Tatami akan sangat unggul jika digunakan untuk mengekstraksi fitur pada data yang secara natur terpisah secara hirarkikal. Jika *grammar* yang dipakai sesuai, maka GE Tatami juga akan sanggup untuk mencari fitur-fitur pemisah data, sekalipun fitur-fitur pemisah data itu tidak ditunjukkan secara eksplisit (seperti pada kasus data sintesis 03)



Gambar 4.6 Decission Tree yang Terbentuk Berdasarkan Penggunaan Fitur-Fitur yang di-generate oleh GE Tatami.

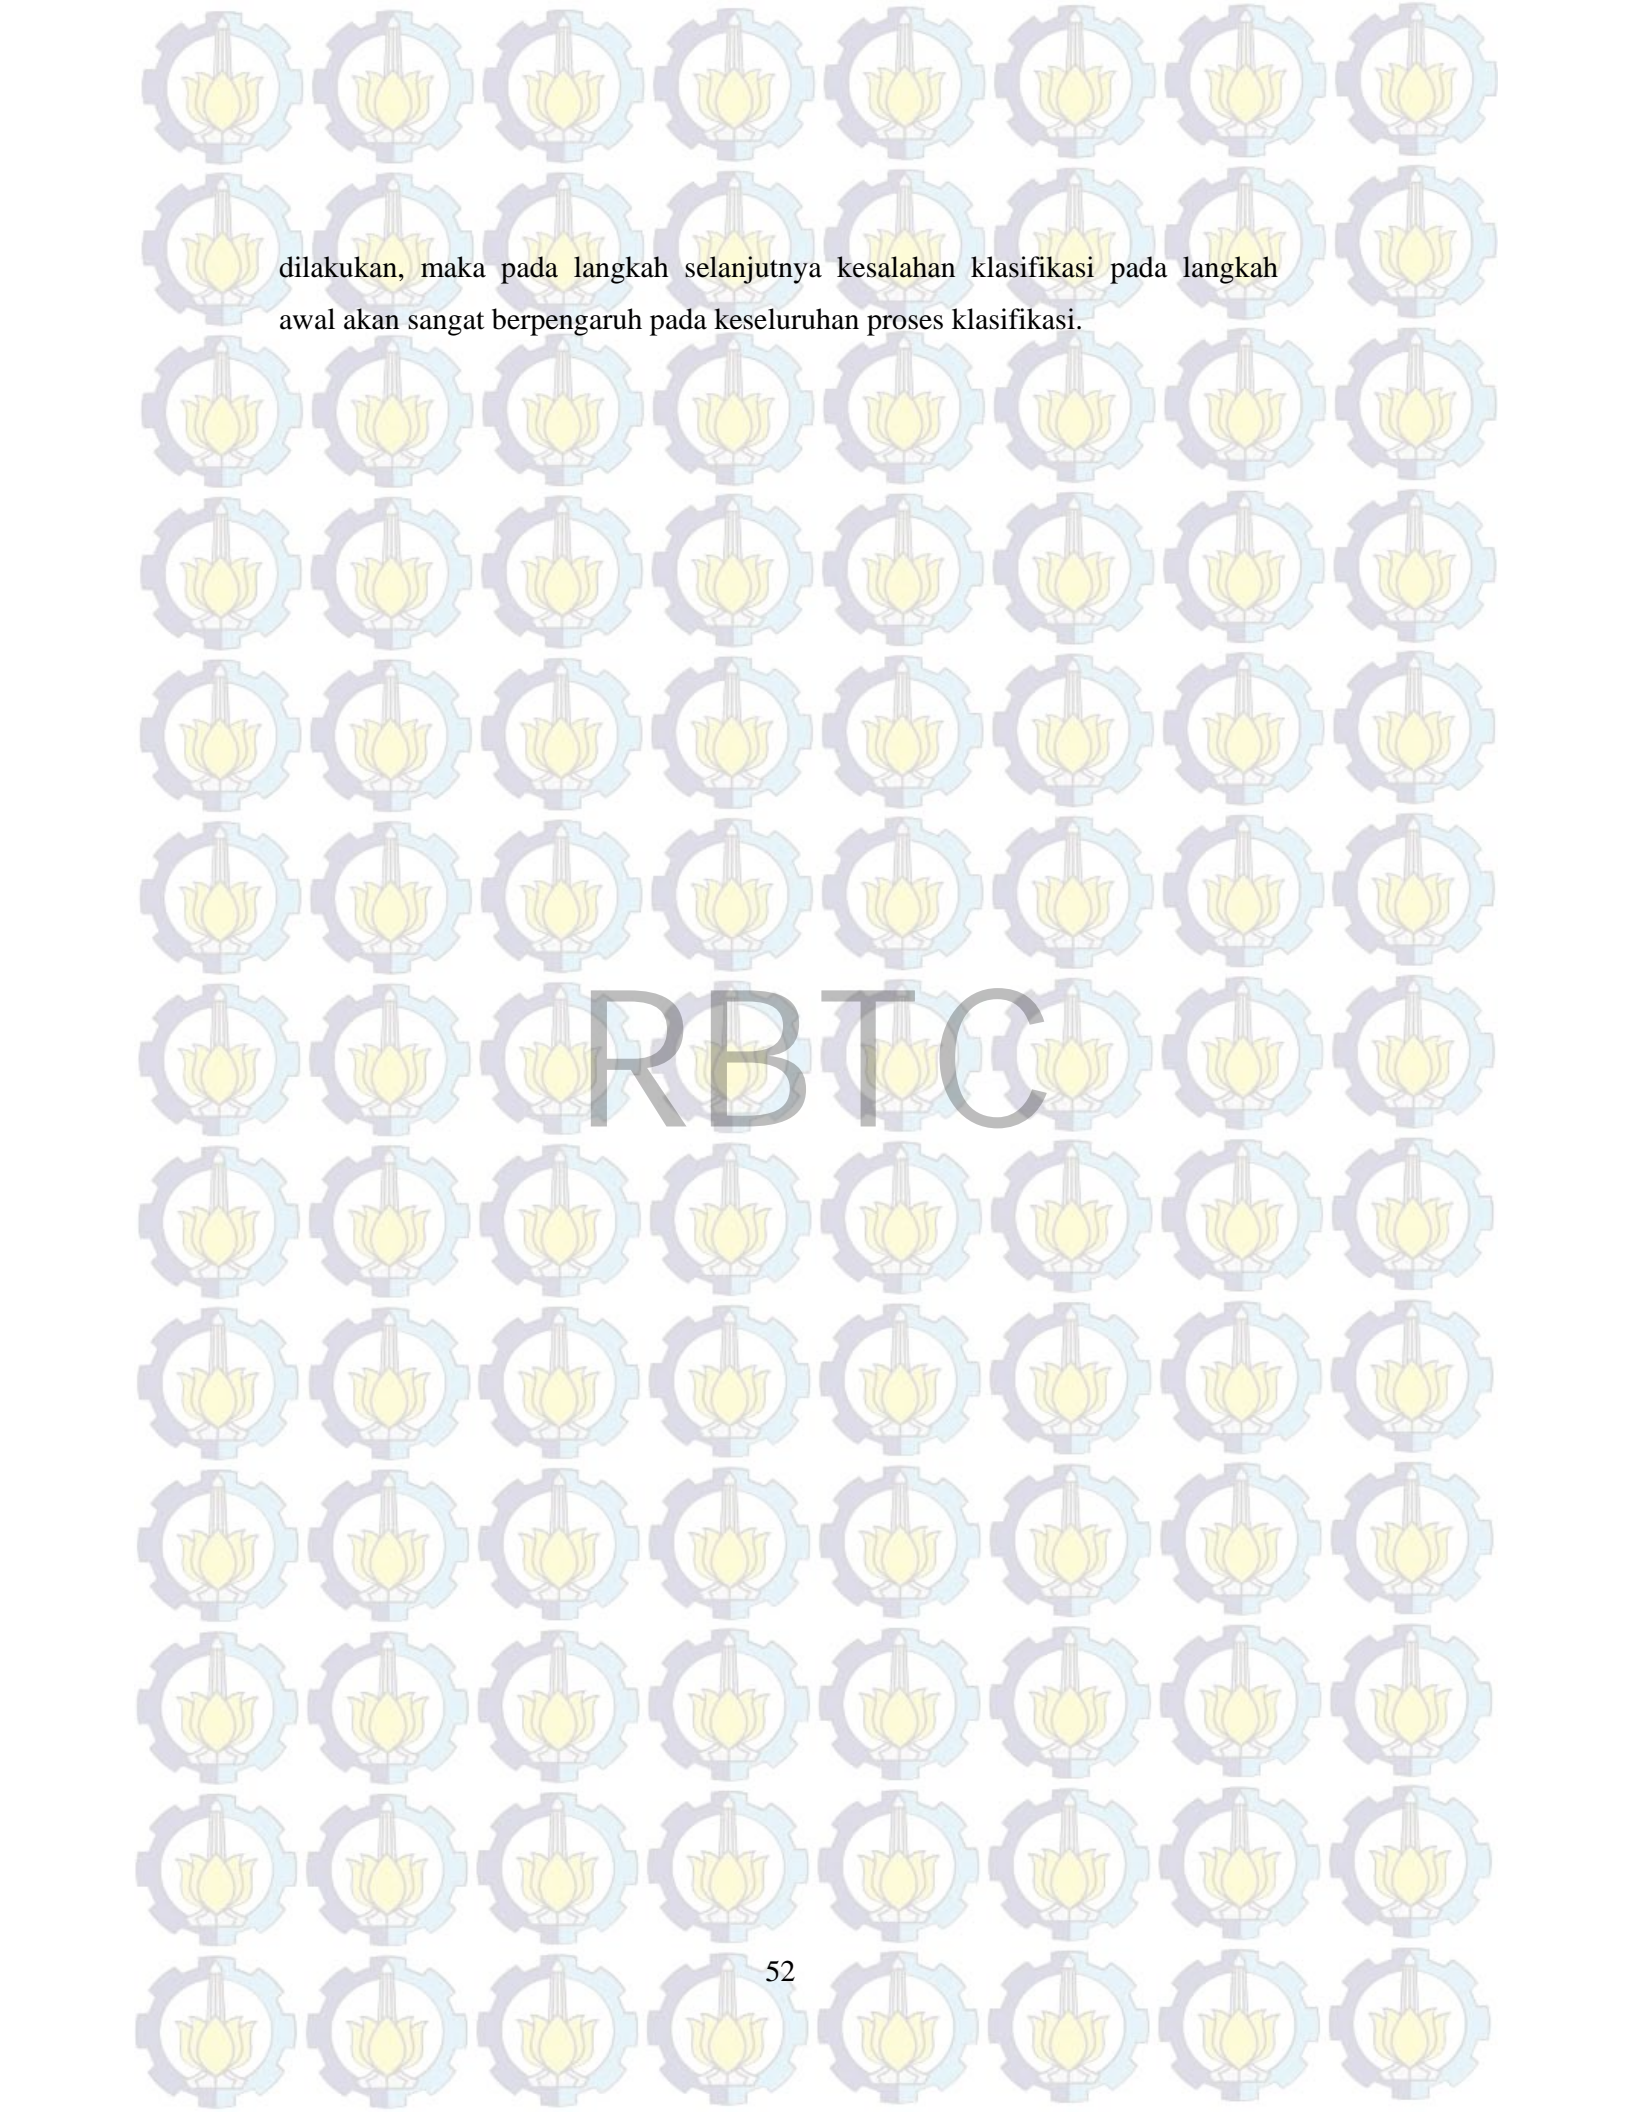


Gambar 4.7 Proyeksi Data terhadap Fitur $(f2) / (f1)$ dan Fitur $(f1) / (f3)$ dengan SVM Classifier.

4.2.2 Kelemahan GE Tatami

Pada semua kasus yang ada, GE Tatami menunjukkan hasil terbaik saat semua data digunakan sebagai training dan testing sekaligus. Namun pada pengujian cross-validation didapati bahwa performa GE Tatami menurun. Terkadang (seperti dalam Fold-2 di dataset E-Coli), sekalipun akurasi yang diberikan dalam training sangat tinggi, akurasi testing nya sangat rendah. Ini menunjukkan bahwa GE Tatami cenderung membuat fitur-fitur yang overfit.

Kelemahan GE Tatami yang lain adalah jika terjadi kegagalan pada langkah pertama, maka langkah-langkah selanjutnya akan menjadi tidak efektif. Pada langkah pertama (*Predefined process* GE Multi pada flowchart di gambar 3.10), GE Tatami harus berhasil menciptakan fitur yang memisahkan satu kelas tertentu dengan semua kelas lainnya secara cukup baik. Jika hal ini gagal



dilakukan, maka pada langkah selanjutnya kesalahan klasifikasi pada langkah awal akan sangat berpengaruh pada keseluruhan proses klasifikasi.